AULAS 14 E 15 Inferência a partir de duas amostras

Ernesto F. L. Amaral

01 e 03 de outubro de 2013 Metodologia de Pesquisa (DCP 854B)

Fonte:

ESTRUTURA DA AULA

- Inferências sobre duas proporções.
- Inferências sobre duas médias: amostras independentes.
- Inferências a partir de amostras emparelhadas.
- Comparação da variância em duas amostras.

VISÃO GERAL

- Os capítulos anteriores (estimação de valores de parâmetros populacionais e teste de hipóteses) envolveram métodos para uma única amostra, usada para se fazer inferência sobre um único parâmetro populacional.
- Na prática, há muitas situações em que desejamos comparar dois conjuntos de dados amostrais.
- Portanto, este capítulo estende os métodos abordados anteriormente para situações que envolvem comparações de duas amostras em vez de apenas uma.

INFERÊNCIAS SOBRE DUAS PROPORÇÕES

INFERÊNCIAS SOBRE DUAS PROPORÇÕES

Objetivo é de usar duas proporções amostrais:

 Para teste de afirmativa sobre duas proporções populacionais.

ou

 Para construção de estimativa de intervalo de confiança da diferença entre proporções populacionais correspondentes.

REQUISITOS

- No teste de hipótese sobre duas proporções populacionais ou na construção de um intervalo de confiança para diferença entre duas proporções populacionais, temos estes requisitos:
 - Temos proporções de duas amostras aleatórias simples independentes (valores amostrais selecionados de uma população não estão relacionados ou emparelhados com valores amostrais selecionados da outra população).
 - Para cada uma das duas amostras, o número de sucessos é, pelo menos, cinco e o número de fracassos também.

NOTAÇÃO PARA DUAS PROPORÇÕES

- Para a população 1, fazemos:
 - $-p_1$ = proporção populacional
 - $-n_1$ = tamanho da amostra
 - $-x_1$ = número de sucessos na amostra

– Proporção amostral:
$$\hat{p}_1 = \frac{x_1}{n_1}$$

$$-\hat{q}_1 = 1 - \hat{p}_1$$

A população 2 possui o mesmo tipo de notação.

PROPORÇÃO AMOSTRAL COMBINADA

 A proporção amostral combinada é simbolizada por *p*-barra e é dada por:

$$\bar{p} = \frac{x_1 + x_2}{n_1 + n_2}$$

– O complementar de p-barra é dado por:

$$\bar{q} = 1 - \bar{p}$$

ESTATÍSTICA DE TESTE PARA DUAS PROPORÇÕES

- Hipótese nula (H_0): $p_1 = p_2$

$$z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\bar{p}\bar{q}}{n_1} + \frac{\bar{p}\bar{q}}{n_2}}}$$

- Onde: $p_1 - p_2 = 0$ (pressuposto na hipótese nula)

$$\hat{p}_1 = \frac{x_1}{n_1}$$
 e $\hat{p}_2 = \frac{x_2}{n_2}$

$$\bar{p} = \frac{x_1 + x_2}{n_1 + n_2}$$
 e $\bar{q} = 1 - \bar{p}$

 Os valores de p e valores críticos são encontrados com base no valor calculado do escore z (Tabela A-2).

ESTIMATIVA DE INTERVALO DE CONFIANÇA

– A estimativa de intervalo de confiança para p_1-p_2 é:

$$(\hat{p}_1 - \hat{p}_2) - E < (p_1 - p_2) < (\hat{p}_1 - \hat{p}_2) + E$$

– Onde a margem de erro E é dada por:

$$E = z_{\alpha/2} \sqrt{\frac{\hat{p}_1 \hat{q}_1}{n_1} + \frac{\hat{p}_2 \hat{q}_2}{n_2}}$$

DETERMINAÇÃO DO NÚMERO DE SUCESSOS x_1 e x_2

- Para calcular os testes de hipótese e intervalos de confiança, é preciso especificar os valores de x_1 , n_1 , x_2 e n_2 .
- Por exemplo, em uma pesquisa com 1.125 pessoas, 47%
 delas disseram que nunca ou raramente viajaram de avião.
 - $-n_1 = 1125$
 - $-\hat{p}_1 = 0.47$
 - Sendo: $x_1 = n_1 * \hat{p}_1$
 - Temos: x_1 = 1125 * 0,47 = 528,75 ≈ 529
- Usamos os valores de n_1 e x_1 , além dos valores da população 2 (não exibidos), nos cálculos de estatística de teste para duas proporções.

TESTES DE HIPÓTESES

 Consideraremos testes de hipóteses sobre duas proporções populacionais:

$$H_0$$
: $p_1 = p_2$

– Sob a suposição de proporções iguais, a melhor estimativa da proporção comum é obtida pela combinação de ambas amostras em uma amostra grande, de modo que p-barra se torna uma estimativa mais óbvia da proporção populacional comum.

EXEMPLO

– Pensar que a política é importante na vida é maior entre homens do que entre mulheres?

nolitica	homem		To+2]
politica			Total
0 1	22,394 15,262	19,634 17,822	42,028 33,084
Total	37,656	37,456	75,112

$$-n_0 = 37.656$$

$$\bar{p} = \frac{x_0 + x_1}{n_0 + n_1} = \frac{15.262 + 17.822}{37.656 + 37.456} = 0,44046224$$

$$-n_1 = 37.456$$

$$-H_0: p_0 = p_1$$

$$-H_1: p_1 > p_0$$

$$-\alpha = 0,05$$

$$z = \frac{(\hat{p}_1 - \hat{p}_0) - (p_1 - p_0)}{\sqrt{\frac{\bar{p}\bar{q}}{n_1} + \frac{\bar{p}\bar{q}}{n_0}}}$$

$$z = \frac{(\frac{17.822}{37.456} - \frac{15.262}{37.656}) - (0)}{\sqrt{\frac{(0,44046224)(0,55953776)}{37.456}}} = 19,46$$

 – P≈0 é menor do que α=0,05. Rejeitamos hipótese nula. Há evidência de que política é mais importante dentre homens.

DESVIO PADRÃO EXATO ≠ ESTIMADO

- Podemos construir uma estimativa de intervalo de confiança da diferença entre proporções populacionais (p_1-p_2) .
- Se um intervalo de confiança não inclui o zero, temos evidência que sugere que p_1 e p_2 tenham valores diferentes.
- O desvio padrão usado para intervalos de confiança é diferente do desvio padrão usado para o teste de hipótese.
 - O teste de hipótese usa desvio padrão exato, baseado na suposição de que não há diferença entre proporções.
 - O intervalo de confiança usa um desvio padrão baseado em valores estimados das proporções populacionais.

INTERVALOS DE CONFIANÇA

- Se desejo é de estimar diferença entre duas proporções, utilize o intervalo de confiança.
- Se desejo é de testar alguma afirmativa sobre duas proporções, use um método de teste de hipótese.
- NÃO teste a igualdade de duas proporções populacionais pela determinação da existência de sobreposição de dois intervalos de confiança individuais.
- A análise da sobreposição de dois intervalos de confiança individuais é mais conservadora (menos rejeição de H_0) do que estimativa de um intervalo de confiança p_1-p_2 .

EXEMPLO DE INTERVALO DE CONFIANÇA

 Use os dados do exemplo anterior para construir intervalo de 95% de confiança para a diferença entre as proporções.

$$-\alpha = 0.05$$

$$-\hat{p}_0 = 15.262/37.656 = 0,4053$$

$$-z_{\alpha/2} = 1,96$$

$$-\hat{p}_1 = 17.822/37.456 = 0,4758$$

- Margem de erro:
$$-\hat{p}_1 - \hat{p}_0 = 0,0705$$

$$E = z_{\alpha/2} \sqrt{\frac{\hat{p}_0 \hat{q}_0}{n_0} + \frac{\hat{p}_1 \hat{q}_1}{n_1}}$$

$$E = 1,96\sqrt{\frac{\left(\frac{15.262}{37.656}\right)\left(\frac{22.394}{37.656}\right)}{37.656}} + \frac{\left(\frac{17.822}{37.456}\right)\left(\frac{19.634}{37.456}\right)}{37.456} = 1,96 * 0,0036 = 0,0071$$

– Intervalo de confiança:

$$(\hat{p}_1 - \hat{p}_0) - E < (p_1 - p_0) < (\hat{p}_1 - \hat{p}_0) + E$$

$$(0,4758-0,4053) - 0,0071 < (p_1 - p_0) < (0,4758-0,4053) + 0,0071$$

$$0,0634 < (p_1 - p_0) < 0,0776$$

INTERPRETAÇÃO DO RESULTADO

- Limites do intervalo de confiança não contêm zero, sugerindo que há diferença significante entre as duas proporções populacionais.
- Temos 95% de confiança que porcentagem de homens que pensam que política é importante é maior do que porcentagem de mulheres que pensam que política é importante por uma quantidade entre 6,34% e 7,76%.

Pr(Z > Z) = 0.0000

RESOLUÇÃO NO STATA

. prtest politica, by(mulher)

Pr(Z < Z) = 1.0000

0: Number of obs = Two-sample test of proportion 37456 Number of obs = 37656 variable Std. Err. [95% Conf. Interval] P > |z|Mean Z .4758116 .0025805 .4808693 0 .470754 .4053006 .4102593 .00253 .4003419 diff .077594 .070511 .0036138 .063428 0.000 under Ho: .0036228 19.46 19.4631 diff = prop(0) - prop(1)Z = Ho: diff = 0Ha: diff < 0на: diff != 0 Ha: diff > 0

- **Teste de hipótese:** a probabilidade de não rejeitarmos H_0 : diff=0 é muito pequena: P(Z>z)=0. Rejeitamos hipótese nula.

Pr(|z| < |z|) = 0.0000

- Aceitamos H₁: diff>0. Há evidência de que política é mais importante para homens (prop₀) do que para mulheres (prop₁).
- Intervalo de confiança: com NC de 95%, diferença das proporções de homens e mulheres varia de 0,0634 a 0,0776.

INFERÊNCIAS SOBRE DUAS MÉDIAS: AMOSTRAS INDEPENDENTES

DEFINIÇÕES DE AMOSTRAS

- Amostras independentes: valores amostrais de uma população não estão relacionados ou combinados com os valores amostrais selecionados da outra população.
 - Ex.: grupo de tratamento e grupo de controle.
- Amostras dependentes: membros de uma amostra podem ser usados para determinar os membros da outra amostra.
 - Consistem em dados emparelhados dependentes, tais como dados de marido/mulher.
 - Dependência pode ocorrer com amostras relacionadas por associações como membros de uma família.
 - Ex.: dados coletados antes e depois de política pública.

INFERÊNCIAS SOBRE DUAS MÉDIAS

- Serão apresentados métodos para uso de dados amostrais provenientes de duas amostras independentes para:
 - Teste de hipóteses sobre duas médias populacionais.
 - Construção de estimativas de intervalos de confiança para diferença entre duas médias populacionais.
- Esses métodos podem ser aplicados a situações em que:
 - Desvios padrões das duas populações são desconhecidos e diferentes. São métodos mais realistas e têm melhor desempenho.
 - Desvios padrões das duas populações são conhecidos.
 - Desvios padrões das duas populações são
 desconhecidos, mas se supõe que sejam iguais.

$\sigma_1 \to \sigma_2$ DESCONHECIDOS E DIFERENTES

- Ao usar duas amostras independentes para testar afirmativa sobre diferença (μ_1 – μ_2) ou para construir intervalo de confiança utilize este requisitos:
 - $-\sigma_1$ e σ_2 são desconhecidos e não se faz suposição sobre igualdade entre eles.
 - Duas amostras são independentes.
 - Amostras aleatórias simples.
 - Uma ou ambas destas condições são satisfeitas:
 - Duas amostras são grandes ($n_1>30$ e $n_2>30$).
 - Amostras provêm de populações com distribuições normais:
 - Em amostras pequenas, procedimentos funcionam se não houver *outliers*.

TESTE DE HIPÓTESE PARA DUAS MÉDIAS

 Para obter estatística do teste de hipótese para duas médias com amostras independentes, utilize:

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

- Ao determinar valores críticos ou valores P, é preciso obter
 o número de graus de liberdade (gl):
 - No livro, gl é o menor número entre n_1 –1 e n_2 –1.
 - Nos pacotes estatísticos:

$$gl = \frac{(A+B)^2}{\frac{A^2}{n_1-1} + \frac{B^2}{n_2-1}} \quad \text{onde: } A = \frac{s_1^2}{n_1} \quad \text{e} \quad B = \frac{s_2^2}{n_2}$$

INTERVALO DE CONFIANÇA PARA $\mu_1 - \mu_2$

– Intervalo de confiança para a diferença μ_1 – μ_2 é:

$$(\bar{x}_1 - \bar{x}_2) - E < (\mu_1 - \mu_2) < (\bar{x}_1 - \bar{x}_2) + E$$

– Onde:

$$E = t_{\alpha/2} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

 Graus de liberdade é o mesmo usado para teste de hipótese.

EXPLORANDO CONJUNTOS DE DADOS

- Antes de realizar teste de hipótese ou construir intervalo de confiança, devemos explorar as duas amostras:
 - Encontrar estatísticas descritivas para ambos conjuntos de dados (n, média e desvio padrão).
 - Fazer diagramas de caixa para os dois conjuntos de dados com a mesma escala.
 - Fazer histogramas do dois conjuntos de dados para comparar suas distribuições.
 - Identificar valores extremos (outliers).

$\sigma_1 \to \sigma_2 CONHECIDOS$

– No caso raro de conhecermos os desvios padrões populacionais, a estatística de teste e o intervalo de confiança se baseiam na distribuição normal em lugar da distribuição t.

– Requisitos:

- Dois desvios padrões populacionais são conhecidos.
- Duas amostras são independentes.
- Amostras aleatórias simples.
- Uma ou ambas destas condições são satisfeitas:
 - Duas amostras são grandes ($n_1>30$ e $n_2>30$).
 - Amostras provêm de populações com distribuições normais. Em amostras pequenas, procedimentos funcionam se não houver *outliers*.

TESTE DE HIPÓTESE PARA DUAS MÉDIAS

– A estatística (z) do teste de hipótese para duas médias de amostras independentes com σ_1 e σ_2 conhecidos é:

$$z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

 Procurar valores P e valores críticos na tabela de distribuição normal padrão (Tabela A-2).

INTERVALO DE CONFIANÇA

– O intervalo de confiança para μ_1 – μ_2 em amostras independentes com σ_1 e σ_2 conhecidos é:

$$(\bar{x}_1 - \bar{x}_2) - E < (\mu_1 - \mu_2) < (\bar{x}_1 - \bar{x}_2) + E$$

– Onde:

$$E = z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

$\sigma_1 \to \sigma_2$ DESCONHECIDOS E IGUAIS

– Se valores de σ_1 e σ_2 não forem conhecidos, mas se for razoável supor que tenham o mesmo valor, as variâncias amostrais podem ser combinadas para estimar σ^2 .

– A estimativa combinada de σ^2 é denotada por s_p^2 .

REQUISITOS PARA σ_1 E σ_2 DESCONHECIDOS E IGUAIS

- Dois desvios padrões populacionais não são conhecidos, mas supõe-se que sejam iguais ($\sigma_1 = \sigma_2$).
- Duas amostras são independentes.
- Amostras aleatórias simples.
- Uma ou ambas destas condições são satisfeitas:
 - Duas amostras são grandes ($n_1>30$ e $n_2>30$).
 - Amostras provêm de populações com distribuições normais:
 - Em amostras pequenas, procedimentos funcionam se não houver *outliers*.

TESTE DE HIPÓTESE

– Estatística do teste de hipótese para duas médias com amostras independentes e com σ_1 igual a σ_2 :

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_p^2}{n_1} + \frac{s_p^2}{n_2}}}$$

– Onde temos a variância combinada:

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{(n_1 - 1) + (n_2 - 1)}$$

– O número de graus de liberdade é dado por $gl=n_1+n_2-2$.

INTERVALO DE CONFIANÇA

– O intervalo de confiança para μ_1 – μ_2 com amostras independentes e com σ_1 e σ_2 iguais é:

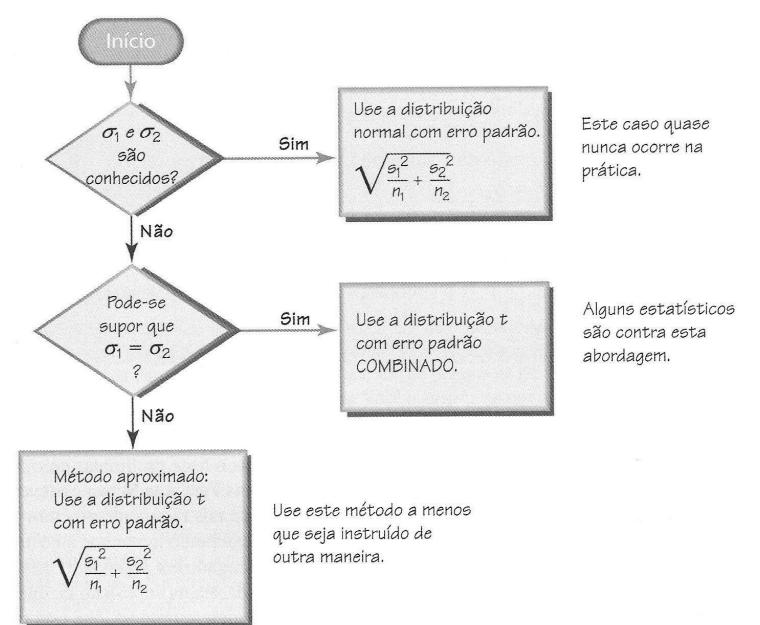
$$(\bar{x}_1 - \bar{x}_2) - E < (\mu_1 - \mu_2) < (\bar{x}_1 - \bar{x}_2) + E$$

– Onde:

$$E = t_{\alpha/2} \sqrt{\frac{s_p^2}{n_1} + \frac{s_p^2}{n_2}}$$

– A variância combinada (s_p^2) e o número de graus de liberdade (n_1+n_2-2) é similar ao do teste de hipótese.

INFERÊNCIA SOBRE DUAS MÉDIAS INDEPENDENTES



INFERÊNCIAS A PARTIR DE AMOSTRAS EMPARELHADAS

INFERÊNCIAS COM AMOSTRAS EMPARELHADAS

 Duas amostras são dependentes se membros de uma amostra podem ser usados para determinarem os membros da outra amostra.

 Ou seja, com dados emparelhados, há alguma relação, de modo que cada valor em uma amostra está emparelhado com um valor correspondente na outra amostra.

REQUISITOS PARA AMOSTRAS EMPARELHADAS

- Dados amostrais consistem em dados emparelhados.
- Amostras aleatórias simples.
- Uma ou ambas destas condições são satisfeitas:
 - Número de pares de dados é grande (n>30).
 - Pares têm diferenças que são provenientes de uma população com distribuição aproximadamente normal.
 - Se houver afastamento radical da distribuição normal,
 não devemos usar os métodos desta seção.

NOTAÇÃO PARA DADOS EMPARELHADOS

- -d = diferença individual entre os dois valores em um único par.
- $-\mu_{\rm d}$ = valor médio das diferenças d para a população de todos os pares.
- -d-barra = valor médio das diferenças d para os dados amostrais emparelhados (igual à média dos valores x y).
- $-s_d$ = desvio padrão das diferenças d para os dados amostrais emparelhados.
- -n = número de pares de dados.

TESTE DE HIPÓTESE

 Estatística de teste de hipótese para dados emparelhados é dada por:

$$d = \frac{\bar{d} - \mu_d}{\frac{S_d}{\sqrt{n}}}$$

- Onde graus de liberdade é igual a n-1.

INTERVALO DE CONFIANÇA

Intervalo de confiança para dados emparelhados é:

$$\bar{d} - E < \mu_d < \bar{d} + E$$

- Onde:

$$E = t_{\alpha/2} \frac{s_d}{\sqrt{n}}$$

EXEMPLO

– Índice de valores racionais (tradicional/secular) é maior entre homens do que entre mulheres?

tab mulher, sum(tradrat5) mean

Mean	mulher		
.2231321	0 1		
.23166243	Total		

RESOLUÇÃO DO EXEMPLO

. ttest tradrat5, by(mulher)

Two-sample t test with equal variances

Interval]	[95% Conf.	Std. Dev.	Std. Err.	Mean	Obs	Group
.2316642	.2146 .2312119	.8676724 .9083252	.0043531	.2231321	39730 40216	0
.2378207	.2255041	.8883898	.003142	.2316624	79946	combined
0046413	0292739		.0062839	0169576		diff
	t : of freedom :	degrees		mean(1)	= mean(0) - = 0	diff =
iff > 0) = 0.9965			на: diff != T > t) =	Pr(iff < 0	

- Teste de hipótese: probabilidade de não rejeitar H₀: diff=0 é muito pequena: P(T<t)=0,0035. Rejeitamos hipótese nula.</p>
- Aceitamos H₁: diff<0. Evidência de menores valores
 seculares entre homens (mean₀) do que mulheres (mean₁).
- Intervalo de confiança: com NC de 95%, diferença das médias de homens e mulheres varia de −0,0293 a −0,0046.

COMPARAÇÃO DA VARIAÇÃO EM DUAS AMOSTRAS

COMPARAÇÃO DA VARIAÇÃO EM DUAS AMOSTRAS

- Esta seção apresenta o teste F que usa duas variâncias amostrais (ou desvios padrões) para a comparação de duas variâncias populacionais (ou desvios padrões).
- O teste F para a comparação de duas variâncias populacionais é muito sensível a afastamentos da distribuição normal.
- Notações de medidas de variação:
 - -s = desvio padrão de amostra
 - $-s^2$ = variância da amostra (desvio padrão amostral ao quadrado).
 - $-\sigma$ = desvio padrão da população.
 - $-\sigma^2$ = variância da população (desvio padrão populacional ao quadrado)

REQUISITOS

- Duas populações são independentes uma da outra:
 - Duas amostras são independentes se amostra selecionada de uma população não se relaciona com amostra selecionada da outra população.

- Duas populações são normalmente distribuídas:
 - Métodos desta seção não são robustos, já que são extremamente sensíveis a afastamentos da normalidade.

TESTES DE HIPÓTESE

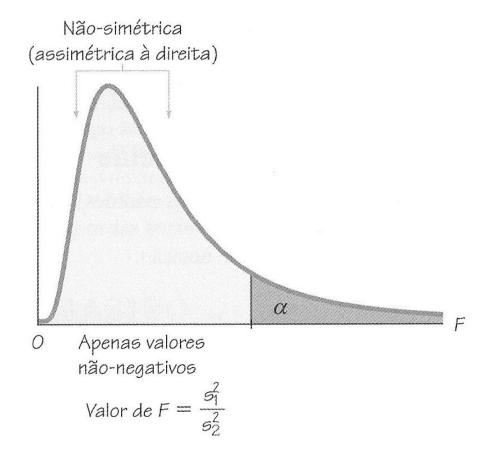
- Notação para testes de hipótese com duas variâncias ou desvios padrões:
 - $-s_1^2$ = maior das duas variâncias amostrais.
 - $-n_1$ = tamanho da amostra com a maior variância.
 - $-\sigma_1^2$ = variância da população da qual se extraiu a amostra com a maior variância.
 - Os símbolos s_2^2 , n_2 e σ_2^2 são usados para a outra amostra e população.
- Estatística de teste de hipótese com duas variâncias:

$$F = \frac{S_1^2}{S_2^2}$$

- Número de graus de liberdade do numerador = n_1 1.
- Número de graus de liberdade do denominador = n_2 2.

DISTRIBUIÇÃO F

– Se realizarmos vários experimentos para selecionar amostras aleatórias de duas populações normalmente distribuídas com variâncias iguais, a distribuição da razão s_1^2/s_2^2 das variâncias amostrais será a distribuição F.



Há uma distribuição F
 diferente para cada par
 distinto de graus de
 liberdade para o
 numerador e o
 denominador.

INTERPRETAÇÃO DA ESTATÍSTICA DE TESTE F

- Se as duas populações têm variâncias iguais, então a razão s_1^2/s_2^2 tende a se aproximar de 1.
- Como s_1^2 é sempre a maior variância, s_1^2 e s_2^2 terão valores muito distantes um do outro se a razão for um número grande.
- Ou seja, valores grandes de F são evidência contra $\sigma_1^2 = \sigma_2^2$.
- A estatística de teste F se aplica a uma afirmativa feita sobre duas variâncias, mas pode ser usada para realizar afirmações sobre dois desvios padrões.

EXEMPLO

– Índice de valores racionais (tradicional/secular) possui desvio padrão maior entre homens do que entre mulheres?

. sdtest tradrat5, by(homem)

Variance ratio test

Group	Obs	Mean	Std. Err.	Std. Dev.	[95% Conf.	Interval]
0 1	40216 39730	.2400897 .2231321	.0045294 .0043531	.9083252 .8676724	.2312119 .2146	.2489674
combined	79946	.2316624	.003142	.8883898	.2255041	.2378207

```
ratio = sd(0) / sd(1) f = 1.0959
Ho: ratio = 1 degrees of freedom = 40215, 39729
Ha: ratio < 1 Ha: ratio != 1 Ha: ratio > 1
Pr(F < f) = 1.0000 2*Pr(F > f) = 0.0000 Pr(F > f) = 0.0000
```

- Teste de hipótese: probabilidade de não rejeitar H₀:
 razão=1, é muito pequena: P(F>f)=0,0000. Rejeitamos H₀.
- Aceitamos H₁: razão>1. Evidência de maior desvio padrão no índice entre mulheres (sd₀) do que entre homens (sd₁).